

DataVision

Modul: Data Science

Dozent: Professor Marcel Spehr

Verfasser:

Mohammad Taiba

6. Semester

Abgabedatum:

07.07.2025

Hochschule:

Fachhochschule Erfurt

Altonaer Straße 25, 99085 Erfurt

Contents

1. Executive Summary.....	2
2. CRISP-DM Phasen.....	2
2.1 Business Understanding	2
2.2 Data Understanding	3
2.3 Data Preparation	6
2.4 Modeling.....	17
2.5 Evaluation	26
2.5.1 Detaillierte Analyse und Ergebnisse der Modelle wurden direkt unter der Data Preparation und Medelling evauliert.....	26
2.5.2 Bewertung in Bezug auf Ziele und Erfolgskriterien:	26
2.6 Deployment	26
Finaler Report:.....	26
Review und Lessons Learned:	27
3. Literaturverzeichnis.....	27

1. Executive Summary

Kurze Zusammenfassung des Projekts: Zielsetzung, Vorgehen, wichtigste Ergebnisse und Fazit.

2. CRISP-DM Phasen

2.1 Business Understanding

- **Business Objectives:**

Das Projekt verfolgt das Ziel, das Preisverhalten und die Volatilität von Bitcoin im Vergleich zu Gold zu analysieren, um Rückschlüsse auf Stabilität, Risiko und Anlageverhalten zu ziehen. Besonderes Augenmerk liegt auf der Wirksamkeit technischer Indikatoren (wie RSI, MACD und Moving Averages), um Markttrends und Handelssignale zu identifizieren.

Dabei sollen mithilfe des CRISP-DM-Modells datengetriebene Erkenntnisse gewonnen werden:

1. Deskriptive Analyse
2. Analytische Untersuchung
3. Statistische Hypothesentests
4. Visualisierung von Mustern, Preisverläufen und technischen Signalen
5. Bewertung von Marktverhalten mithilfe technischer Indikatoren

- **Business Success Criteria:**

1. Es wurde ein signifikanter Unterschied in der Volatilität zwischen Bitcoin und Gold festgestellt.
2. Technische Indikatoren (z. B. RSI, MACD) zeigen eine statistisch signifikante Beziehung zur Kursentwicklung.
3. Die Analyse identifiziert mindestens drei wiederkehrende technische Signale oder Muster.
4. Hypothesentests bestätigen signifikante Unterschiede im Marktverhalten ($p < 0.05$).
5. Es können fundierte Aussagen über die Stabilität und das Investitionsverhalten der beiden Assets getroffen werden.

- **Data Mining Goals:**

1. Quantitative Analyse der Preisvolatilität von Bitcoin und Gold anhand statistischer Kennzahlen (Mittelwert, Standardabweichung, IQR).
2. Untersuchung der Korrelation zwischen Preisverläufen und technischen Indikatoren wie RSI, MACD, Bollinger Bands und Moving Averages.

3. Anwendung von Hypothesentests (t-Test, ANOVA, Chi²-Test) zur Validierung von Marktverhalten und Mustererkennung.
4. Visualisierung von Kursverläufen und technischen Signalen zur Erkennung potenzieller Handelsmuster.
5. Identifikation signifikanter technischer Indikatoren, die zur Prognose von Kursentwicklungen beitragen könnten.

- **Data Mining Success Criteria:**

1. Statistische Kennzahlen (Mittelwert, Median, Standardabweichung, IQR) wurden korrekt berechnet und interpretiert.
2. Konfidenzintervalle für alle vier Kennzahlen wurden erfolgreich bestimmt.
3. Drei unterschiedliche Hypothesentests (t-Test, ANOVA, Chi²-Test) wurden mit Bootstrap-Sampling durchgeführt und ausgewertet.
4. Es wurden signifikante Korrelationen ($|r| > 0.5$) zwischen technischen Indikatoren und Kursverlauf festgestellt.
5. Alle geplanten Visualisierungen (Streudiagramm, Hex-Binning, Boxplot) wurden erstellt und sinnvoll interpretiert.
6. Die Analyse ist vollständig reproduzierbar im Jupyter Notebook dokumentiert.

2.2 Data Understanding

- **Auswahl und Beschreibung der Datensätze:**

Für die Analyse wurden zwei unterschiedliche Finanzdatensätze zur Untersuchung des Preisverhaltens und der Volatilität von Bitcoin und Gold verwendet.

1. **BTCUSD_1d_analysis.csv**

Enthält tägliche Preisdaten für Bitcoin (BTC/USD) mit den Spalten [Date, Open, High, Low, Close, Volume BTC, Volume USD, symbol, unix].

Der Datensatz umfasst 3.805 Einträge und deckt den Zeitraum von 2014 bis 2025 ab.

Die Daten wurden vollständig eingelesen und enthalten keine fehlenden Werte.

Quelle: https://www.cryptodatadownload.com/cdd/Bitstamp_BTCUSD_d.csv

2. **XAUUSD_1d_analysis.csv**

Enthält tägliche Preisdaten für Gold (XAU/USD) mit den Spalten [Date, Open, High, Low, Close, Volume].

Der Datensatz besteht aus 5.295 Einträgen ab dem Jahr 2004.

Beim Einlesen war eine Angabe des Trennzeichens (sep=';') notwendig, da die Datei mit Semikolon formatiert war. Nach Umwandlung aller relevanten Spalten in numerische Formate konnten ebenfalls vollständige Daten ohne fehlende Werte bestätigt werden.

Quelle: <https://www.kaggle.com/datasets/novandraanugrah/xauusd-gold-price-historical-data-2004-2024>

• Erste Analysen:

Zur ersten quantitativen Einschätzung der Daten wurden zentrale Kennzahlen mittels describe() erzeugt:

Bitcoin (BTC/USD):

- Durchschnittlicher Schlusskurs (Close): 22.170 USD
- Standardabweichung: 25.157 USD
- Min–Max: 162 – 106.187 USD
- Aussage: Hohe Streuung → sehr volatile Kursentwicklung

Gold (XAU/USD):

- Durchschnittlicher Schlusskurs (Close): 1.320 USD
- Standardabweichung: ca. 501 USD
- Min–Max: 382 – 2.799 USD
- Aussage: Deutlich stabilerer Kursverlauf im Vergleich zu BTC

Die Datentypen wurden überprüft und ggf. in numerische Formate konvertiert. Alle Zeitangaben liegen im täglichen Intervall vor.



Abbildung 1: Täglicher Verlauf der Schlusskurse - BTC und XAU (logarithmisch)




Abbildung 2: Histogramme für Vergleich zwischen Preise und technischen Indikatoren für BTC und XAU nebeneinander

Hier eine kurze Interpretation je Paar:

1. Close (Schlusskurs)

- **BTC:** Sehr breite Verteilung, viele Werte < 20.000 USD, einige Ausreißer bis > 100.000.
- **XAU:** Konzentration um 1200–2000 USD, mehrgipflige Verteilung, typisch für Goldpreisbewegungen.

2. MACD (Trendindikator)

- **BTC:** Spitze bei 0, symmetrisch – typisch für volatilere Assets.
- **XAU:** Linksteil, rechtsschief – signalisiert konservativere Trendwechsel.

3. RSI (Relative Stärke)

- Beide: Glockenform mit Schwerpunkt bei 40–60 – typisch für Märkte ohne ständige Überkauft-/Überverkauft-Zustände.

4. MA_20 (20-Tage-Durchschnitt)

- **BTC:** Ähnlich wie der Schlusskurs, viele kleinere Werte.
- **XAU:** Mehrere Peaks – entspricht verschiedenen Preisniveaus über Zeit.

5. Volumen

- **BTC:** Viele Einträge mit sehr kleinem Volumen, einige riesige – hohe Volatilität.
- **XAU:** Konzentration im mittleren Bereich – stabileres Handelsvolumen.

Fazit: BTC zeigt volatilere, breiter gestreute Werte; XAU ist stabiler, mit klareren Preisclustern. Die technische Analyse spiegelt die typischen Marktcharakteristika beider Assets gut wider.

2.3 Data Preparation

• Datenbereinigung und Aufbereitung:

1. BTCUSD_1d_analysis.csv – Tagesdaten für Bitcoin

Schritte:

1. Einlesen und Standardisierung:
 - Die CSV-Datei wurde mittels `pandas.read_csv()` eingelesen.
 - Spaltennamen wurden in Kleinbuchstaben umgewandelt und Leerzeichen durch Unterstriche ersetzt.
2. Zeitformat und Duplikate:
 - Die Datumsangabe wurde in ein UTC-basiertes `datetime`-Format konvertiert.
 - Es erfolgte die Entfernung von Duplikaten auf Basis des `date`-Feldes.
3. Selektion und Umbenennung:
 - Es wurden nur die relevanten Spalten (`date`, `open`, `high`, `low`, `close`, `volume_usd`) behalten.
 - Umbenennung zu BTC-spezifischen Spaltennamen wie `open_btc`, `close_btc` etc., um spätere Fusionen mit anderen Datensätzen zu erleichtern.
4. Berechnung technischer Indikatoren:

- Indikatoren: Für jeden Zeitpunkt wurden folgende technische Indikatoren berechnet und als neue Spalten hinzugefügt:
 1. RSI_btc (Relative-Strength-Index)
 2. MACD_btc (Moving Average Convergence Divergence)
 3. MA_20_btc (20-Tages Moving Average)
 4. Trendline_btc (Trendlinien-Indikator, basierend auf gewählter Methode)
 - Volumen: Das Volumen wurde als volume_btc übernommen.
5. Sortierung und Export:
- Sortierung der Daten nach Datum und Rücksetzung des Indexes.
 - Speicherung der bereinigten Daten in eine separate CSV-Datei.

2. XAUUSD_1d_analysis.csv – Tagesdaten für Gold

Schritte:

1. Einlesen und Trennzeichen:
 1. Aufgrund der Formatierung mit Semikolon (;) musste dies explizit als Trennzeichen angegeben werden.
 2. Auch hier erfolgte die Vereinheitlichung der Spaltennamen.
2. Datumsformat und Duplikate:
 1. Das Datumsformat lag im deutschen Format vor (%d.%m.%Y %H:%M) und wurde in UTC-Zeitstempel konvertiert.
 2. Duplikate und fehlende Werte wurden anhand der Kernspalten entfernt.
3. Selektion und Umbenennung:
 1. Relevante Spalten (date, open, high, low, close, volume) wurden ausgewählt und zu *_xau umbenannt.
4. Berechnung technischer Indikatoren:
 - Indikatoren: Analog zu BTC wurden folgende Indikatoren berechnet:
 1. RSI_xau
 2. MACD_xau
 3. MA_20_xau
 4. Trendline_xau
 - Volumen: Übernommen als volume_xau.
5. Sortierung und Export:
 1. Sortierung nach Datum, Index zurückgesetzt und die bereinigten Daten exportiert.

• Datenintegration:

Zielsetzung:

Ziel dieser Integration war es, die bereinigten Tagesdaten beider Assets (BTC und XAU) anhand des gemeinsamen Zeitmerkmals zusammenzuführen, um eine direkte Vergleichbarkeit und gemeinsame Analyse zu ermöglichen.

Vorgehensweise:

1. Einlesen der bereinigten Datensätze:
 - Die beiden zuvor gespeicherten bereinigten CSV-Dateien BTCUSD_1d_analysis_clean.csv und XAUUSD_1d_analysis_clean.csv wurden mit parse_dates eingelesen, um die Datumsspalten direkt als datetime-Objekte zu interpretieren.
2. Harmonisierung der Zeitspalten:
 - Da die Datensätze ursprünglich jeweils eine eigene Zeitspalte (date_btc bzw. date_xau) enthielten, wurden diese zur Vorbereitung der Fusion beide auf einen einheitlichen Spaltennamen date umbenannt.
3. Merge-Vorgang:
 - Die Zusammenführung erfolgte mit einem inner join auf der gemeinsamen date-Spalte. Dadurch wurden nur die Tage berücksichtigt, an denen beide Assets gleichzeitig einen Kurswert aufweisen.
 - Dies stellt sicher, dass alle nachfolgenden Analysen auf vollständig synchronisierten Daten basieren.
4. Sortierung und Speicherung:
 - Der integrierte Datensatz wurde chronologisch sortiert und als neue CSV-Datei final_merged_dataset.csv gespeichert.
 - Diese Datei stellt die finale Grundlage für alle korrelationsbasierten, vergleichenden und prädiktiven Analysen im weiteren Projektverlauf dar.

Ergebnis:

Der resultierende DataFrame enthält nun pro Tag die folgenden Informationen in einer Zeile:

- Bitcoin: open_btc, high_btc, low_btc, close_btc, RSI_btc, MACD_btc, MA_20_btc, Trendline_btc, volume_btc
- Gold: open_xau, high_xau, low_xau, close_xau, RSI_xau, MACD_xau, MA_20_xau, Trendline_xau, volume_xau

• Berechnungen:

Zielsetzung:

Ziel der Berechnungen war es, die zentralen Tendenzen (Mittelwert, Median) und die Streuung (Standardabweichung, Interquartilsabstand) der Schlusskurse beider Assets zu analysieren und mit 95 %-Konfidenzintervallen zu bewerten.

Vorgehensweise:

1. Deskriptive Kennzahlen:

Für den jeweiligen Schlusskurs (close_btc, close_xau) wurden folgende Werte bestimmt:

- Mittelwert (arithmetisches Mittel)
- Median (Zentralwert)
- Standardabweichung (Maß für Volatilität)
- IQR – Interquartilsabstand (Differenz zwischen dem 75. und 25. Perzentil)

2. Konfidenzintervalle:

- Für den Mittelwert wurde ein zweiseitiges Intervall mit der t-Verteilung berechnet.
- Für Median, Standardabweichung und IQR wurde Bootstrap-Sampling mit 1.000 Ziehungen eingesetzt, um robuste Konfidenzschätzungen zu erhalten.

Ergebnis:

Bitcoin (BTC) – Schlusskurs close_btc:

Kennzahl	Wert	95 %-Konfidenzintervall
Mittelwert	20.518,35 USD	(19.629,27 ; 21.407,43)
Median	9.635,40 USD	(9.280,85 ; 10.203,65)
Standardabweichung	23.199,40 USD	(22.400,26 ; 23.972,62)
IQR	30.377,52 USD	(27.731,06 ; 33.647,98)

Gold (XAU) – Schlusskurs close_xau:

Kennzahl	Wert	95 %-Konfidenzintervall
Mittelwert	1.607,55 USD	(1.592,11 ; 1.623,00)
Median	1.527,12 USD	(1.492,78 ; 1.595,57)
Standardabweichung	403,14 USD	(391,90 ; 413,98)
IQR	612,96 USD	(598,71 ; 631,68)

• Visualisierungen:

1. Streudiagramme

- 1) Das Streudiagramm zeigt die Beziehung zwischen dem BTC-Preis und dem XAU-Preis (Gold) über verschiedene Jahre. Die Visualisierung hilft, mögliche Korrelationen oder Trends zwischen den beiden Werten zu erkennen.




Abbildung 3: Streudiagramm – BTC-Schlusskurs vs. XAU-Schlusskurs

- 2) Um den Zusammenhang zwischen technischen Indikatoren (RSI, MACD, gleitender Durchschnitt MA20) und dem Preis für BTC sowie XAU (Gold) zu untersuchen, wurden sechs Streudiagramme in einer gemeinsamen Abbildung verwendet. Die Farbgebung zeigt zusätzlich das jeweilige Handelsvolumen an.




Abbildung 4: Streudiagramme – RSI, MACD und MA20 vs. Preis (BTC und XAU) unter Einbezug des Handelsvolumens

2. Boxplots

Der Boxplot veranschaulicht die Verteilung der täglichen Renditen von BTC und XAU. Dadurch werden Unterschiede in Median, Streuung und Ausreißern der beiden Assets sichtbar.




Abbildung 5: Boxplot der täglichen Renditen von BTC und XAU

3. Hexagonal Binning

- 3) Hexagonales Binning (hexbin) wird verwendet, um die gemeinsame Verteilung der täglichen Renditen von BTC und XAU in einer dicht besiedelten Punktwolke darzustellen. Die Methode hilft, Bereiche mit hoher Punktdichte besser zu visualisieren.




Abbildung 6: Hexagonales Binning der täglichen Renditen von BTC und XAU

- 4) Siehe die Abbildung: [Abbildung 7: Hexagonales Binning – Korrelation zwischen BTC- und XAU-Schlusskursen](#)

• Analysen:

4. Korrelationen

- 1) Zur Analyse der linearen Beziehung zwischen BTC- und XAU-Schlusskurs wurde ein hexagonales Binning-Diagramm erstellt. Zusätzlich wurde der Pearson-Korrelationskoeffizient berechnet und im Titel dargestellt. Dies ermöglicht eine schnelle Einschätzung der Zusammenhänge zwischen beiden Märkten.




Abbildung 7: Hexagonales Binning – Korrelation zwischen BTC- und XAU-Schlusskursen

- 2) Die Korrelationsmatrix wurde für BTC und Gold jeweils einzeln (interne Korrelation) sowie zwischen BTC- und Gold-Variablen (Cross-Korrelation) berechnet und als Heatmap visualisiert. So lassen sich Zusammenhänge zwischen Preisen, technischen Indikatoren und Volumen schnell erkennen.



Abbildung 8: Korrelationsmatrixen - Interne Zusammenhänge bei BTC und Gold sowie Cross-Korrelationen

5. Kontingenz- und Kreuztabellen

- 1) Siehe die Abbildung: [Abbildung 8: Korrelationsmatrixen - Interne Zusammenhänge bei BTC und Gold sowie Cross-Korrelationen](#)
- 2) Es wurde eine Kontingenztafel erstellt, um die gleichzeitigen Aufwärtsbewegungen (Kursanstiege) von Bitcoin (BTC) und Gold (XAU) zu untersuchen. Die Heatmap visualisiert, wie häufig der Kurs von BTC im Tagesverlauf gefolgt von/oder begleitet von einer positiven Kursbewegung bei Gold war.




Abbildung 9: Kontingenztabelle als Heatmap – Gemeinsame Kursbewegungen
BTC und Gold (Up/Down-Verhalten)

- 3) Eine Kontingenztabelle wurde erstellt, um die Häufigkeit von gemeinsamen Preisbereichen von Bitcoin (BTC) und Gold (XAU) zu analysieren. Dabei wurden die Preise für BTC und XAU in festgelegte Intervalle unterteilt und die Kombinationen gezählt. Eine Heatmap visualisiert, wie häufig bestimmte Preisbereiche von BTC mit bestimmten Preisbereichen von XAU gemeinsam auftreten.




Abbildung 10: Heatmap - BTC vs. XAU Preisbereiche

- 4) Eine Kontingenztabelle wurde zur Analyse der gleichzeitigen Renditebewegungen von Bitcoin (BTC) und Gold (XAU) erstellt. Die täglichen Renditen wurden in drei Kategorien eingeteilt („Steigend“, „Neutral“, „Fallend“), abhängig von einer relativen Schwelle von $\pm 0,5\%$. Die Kontingenztabelle zeigt, wie häufig bestimmte Renditekategorien für BTC und XAU gemeinsam auftreten.

Ausgabe der Kontingenztabelle:

BTC\XAU	Fallend	Neutral	Steigend
Fallend	248	533	225
Neutral	111	238	100
Steigend	238	594	331

2.4 Modeling

- **Hypothesentests:**

- **t-Test:**

- 1) **Fragestellung:**

- Unterscheidet sich die Volatilität (gemessen als absolute tägliche Renditen) von Bitcoin (BTC) signifikant von der von Gold (XAU)?

- Durchführung:**

- Mittels Bootstrap-Sampling wurden die Mittelwerte der absoluten täglichen Renditen von BTC und XAU verglichen. Es wurden 10.000 Bootstrap-Stichproben gezogen, um die Verteilung der Differenzen zu schätzen.

- Ergebnisse:**

- Mittlere Differenz der Volatilitäten (BTC - XAU): 0.0222
 - 95%-Konfidenzintervall: [0.0209, 0.0235]

- Visualisierung:**

- Die Abbildung zeigt die Dichteverteilung der absoluten täglichen Renditen für BTC und XAU.




Abbildung 11: Dichteverteilung der absoluten täglichen Renditen (Volatilität) von BTC und XAU

2) Fragestellung:

Gibt es für ausgewählte Kennzahlen (RSI, MACD, gleitender Durchschnitt MA20, Volumen, Preis) einen signifikanten Unterschied im Mittelwert zwischen Bitcoin (BTC) und Gold (XAU)?

Durchführung:

Für jedes Merkmalspaar wurden die Mittelwerte der beiden Gruppen verglichen und ein Bootstrap-Test durchgeführt. Hierbei wurden die Daten kombiniert und via Permutation (zufällige Zuweisung) die Verteilung der Mittelwertdifferenzen simuliert.

Ergebnisse:

RSI – Bootstrapped p-Wert: 0.0000 Signifikanter Unterschied bei RSI zwischen BTC und Gold.
MACD – Bootstrapped p-Wert: 0.0000 Signifikanter Unterschied bei MACD zwischen BTC und Gold.
MA20 – Bootstrapped p-Wert: 0.0000 Signifikanter Unterschied bei MA20 zwischen BTC und Gold.
Volumen – Bootstrapped p-Wert: 0.0000 Signifikanter Unterschied bei Volumen zwischen BTC und Gold.
Preis – Bootstrapped p-Wert: 0.0000 Signifikanter Unterschied bei Preis zwischen BTC und Gold.

○ ANOVA:

1) Fragestellung:


Beeinflussen Asset-Typ (BTC vs. XAU) und Jahr signifikant die Rendite? Gibt es einen Interaktionseffekt (Asset $\times$ Jahr)?

Durchführung:

Modell: Zwei-Weg-ANOVA mit Interaktion: $\text{ret} \sim \text{C}(\text{asset}) * \text{C}(\text{year})$

Bootstrapping: Zur Robustheit wurde die ANOVA mittels Bootstrap-Sampling wiederholt (n=1000), um empirische p-Werte zu berechnen.

Ergebnisse:



	F-Wert (orig)	emp. p-Wert
Asset (BTC vs XAU)	9.9242	0.001
Jahr	2.6123	0.003
Asset $\times$ Jahr	2.1557	0.020

✦ Interpretation der Bootstrap-ANOVA:

- ✓ Asset (BTC vs XAU): Signifikanter Effekt (emp. p = 0.0010)
- ✓ Jahr: Signifikanter Effekt (emp. p = 0.0030)
- ✓ Asset $\times$ Jahr: Signifikanter Effekt (emp. p = 0.0200)

Abbildung 12: Ergebnis für erste ANOVA-Analyse

2) Fragestellung:

Unterscheiden sich die durchschnittlichen Renditen von Bitcoin (BTC) signifikant zwischen den Monaten?

Durchführung:

Modell: Einfaktorielle ANOVA für Monatsrenditen: $\text{ret_btc} \sim \text{C}(\text{month})$

Bootstrapping: Zur Absicherung der Ergebnisse wurde die ANOVA mit 1000 Bootstrap-Iterationen wiederholt. So wird die Verteilung der F-Werte unter der Nullhypothese geschätzt und ein empirischer p-Wert berechnet.

Ergebnisse:

- F-Wert (original): 1.0769
- Empirischer p-Wert: 0.3700
- Interpretation:
 - Signifikant ($p < 0.05$):
Die durchschnittlichen monatlichen Renditen unterscheiden sich signifikant.
 - Nicht signifikant ($p \geq 0.05$):

Es gibt keinen signifikanten Unterschied zwischen den Monaten.

- Visualisierung:




Abbildung 13: Ergebnis für zweite ANAOVA-Analyse (Verteilung der Bootstrap-F-Werte)

2) Fragestellung:

Unterscheiden sich die Mittelwerte des BTC-Preises signifikant, wenn das Handelsvolumen von Gold (XAU) in drei Gruppen (niedrig, mittel, hoch) unterteilt wird?

Durchführung

Gruppenbildung: Das Gold-Volumen wurde in drei Quantile (niedrig, mittel, hoch) unterteilt.

Testverfahren: Ein Bootstrap-Test wurde durchgeführt, indem die beobachtete maximale Mittelwertdifferenz des BTC-Preises zwischen den Gruppen mit der unter der Nullhypothese simulierten Verteilung verglichen wurde (10.000 Iterationen).

p-Wert-Berechnung: Der empirische p-Wert gibt die Wahrscheinlichkeit an, mindestens so große Differenzen unter der Nullhypothese (kein Unterschied zwischen den Gruppen) zu beobachten.

Ergebnisse:

- Bootstrapped p-Wert: 0.0000
- Interpretation:
- Signifikant ($p < 0.05$):

Es gibt einen signifikanten Unterschied im BTC-Preis zwischen den Volumen-Gruppen von Gold.

- Nicht signifikant ($p \geq 0.05$):
Es gibt keinen signifikanten Unterschied.
- Visualisierung:




Abbildung 14: Ergebnis für dritte ANOVA-Analyse (BTC-Preis in Abhängigkeit vom Gold-Handelsvolumen (niedrig, mittel, hoch))

○ **Chi-Quadrat-Test:** [Fragestellung, Ergebnisse]

Fragestellung:

Gibt es einen signifikanten Zusammenhang zwischen den Kursveränderungen (Up/Down) von Bitcoin (BTC) und Gold (XAU)?

Durchführung:

- **Statistischer Test:** Klassischer Chi-Quadrat-Test auf die Kontingenztabelle der Kursveränderungen.
- **Bootstrapping:** Zur Robustheit wurde der χ^2 -Test mit 1.000 Bootstrap-Iterationen wiederholt, um einen empirischen p-Wert zu bestimmen.
- **Interpretation:** Die beobachtete χ^2 -Statistik wird mit der simulierten Verteilung verglichen.

Ergebnisse:

- Beobachtete χ^2 -Statistik: 15.6791
- Empirischer p-Wert: 0.0000
- Freiheitsgrade: 1

- Interpretation:
 - Signifikant ($p < 0.05$):
Es besteht ein signifikanter Zusammenhang zwischen den Kursveränderungen von BTC und XAU.
 - Nicht signifikant ($p \geq 0.05$):
Es gibt keinen signifikanten Zusammenhang.
- Visualisierung:




Abbildung 15: Ergebnis für Chi-Quadrat-Test (Verteilung der Bootstrap-Chi²-Statistik im Vergleich zur beobachteten Statistik)

- **Weitere Modelle:**

- **Multiple Lineare Regression**

Im Jupyter Notebook wird zunächst ein Datensatz mit technischen Indikatoren für Bitcoin (BTC) und Gold (XAU) eingelesen. Es werden nur vollständige Zeilen verwendet, um die Datenqualität sicherzustellen. Die relevanten Features sind RSI, MACD und gleitender Durchschnitt (MA) jeweils für BTC und XAU, während der BTC-Schlusskurs als Zielvariable dient. Der Datensatz wird nach Zeitstempel sortiert und in Trainings- und Testdaten aufgeteilt, wobei 80% der Daten für das Training verwendet werden. Das Modell basiert auf klassischer linearer Regression mit statsmodels, wobei ein Interzept hinzugefügt wird. Nach dem Training wird eine Modellzusammenfassung ausgegeben, die wichtige Kennzahlen wie Koeffizienten und Konfidenzintervalle enthält. Mit dem trainierten Modell werden anschließend Vorhersagen für die Testdaten gemacht. Zur Bewertung der Modellgüte werden das Bestimmtheitsmaß (R^2) und der quadratische Fehler (RMSE) berechnet. Die Ergebnisse werden visuell dargestellt: Einerseits als Scatterplot, der Vorhersage und Realität direkt gegenüberstellt, andererseits als Zeitreihendiagramm, das die Entwicklung des

Vorhersagemodells und der tatsächlichen BTC-Preise über die Zeit vergleicht. So entsteht ein umfassender Einblick in die Modellgüte und die Prognosefähigkeit des linearen Modells.

Ergebnisse:

- 1) **Erklärung:** Die Tabelle zeigt die Ergebnisse einer linearen Regression (OLS). Sie enthält wichtige Kennzahlen wie das Bestimmtheitsmaß (R^2), die Anpassungsgüte des Modells, statistische Tests sowie die geschätzten Koeffizienten und deren Konfidenzintervalle für alle Einflussgrößen. Zusätzlich sind die standardisierten Fehler (std err), t-Werte, p-Werte und die Spannweite der 95%-Konfidenzintervalle aufgeführt.

OLS Regression Results

Dep. Variable:close_btc

R-squared:0.994

Model:OLS

Adj. R-squared:0.994

Method:Least Squares

F-statistic:5.615e+04

Date:Sun, 08 Jun 2025

Prob (F-statistic):0.00

Time:07:06:03

Log-Likelihood:-17817.

No. Observations:2080

AIC:3.565e+04

Df Residuals:2073

BIC:3.569e+04

Df Model:6

Covariance Type:nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

const

-3567.4957

324.612

-10.990

0.000

-4204.096

-2930.895

RSI_btc

35.8525

2.379

15.073

0.000

31.188

40.517

MACD_btc

1.3073

0.034

38.480

0.000

1.241

1.374

MA_20_btc

0.9797

0.003

350.495

0.000

0.974

0.985

RSI_xau

6.2429

3.855

1.620

0.105

-1.316

13.802

MACD_xau

-10.5090

3.498

-3.004

0.003

-17.370

-3.648

MA_20_xau

1.1220

0.164

6.831

0.000

0.800

1.444

Omnibus:341.143

Durbin-Watson:0.373

Prob(Omnibus):0.000

Jarque-Bera (JB):6118.535

Skew:0.108

Prob(JB):0.00

Kurtosis:11.400

Cond. No.2.44e+05

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 2.44e+05. This might indicate that there are strong multicollinearity or other numerical problems.

R² (Bestimmtheitsmaß): 0.9918

RMSE (Root Mean Squared Error): 2133.65

Abbildung 16: Modellergebnisse der MLR

- 2) **Erklärung:** Die Abbildung besteht aus zwei Diagrammen:
 - Im linken Diagramm (Scatterplot) werden die vorhergesagten BTC-Preise gegen die tatsächlichen Werte abgetragen, um die Modellgüte zu veranschaulichen. Die rote Linie markiert die perfekte Vorhersage.

- Im rechten Diagramm (Zeitreihenplot) werden der tatsächliche und der prognostizierte BTC-Preis über die Zeit dargestellt, sodass systematische Abweichungen und Trends im Zeitverlauf erkennbar sind.




Abbildung 17: Vergleich der tatsächlichen und vorhergesagten BTC-Preise sowie deren zeitlicher Verlauf

○ Naiver Bayes und Lineare Diskriminanzanalyse

1. Datenaufbereitung und Klassifikationsziel

Die Klassifikation erfolgt auf Basis von technischen Indikatoren (RSI, MACD, gleitender Durchschnitt, Trendlinien) von Bitcoin (BTC) und Gold (XAU). Die Zielvariable besteht aus drei Marktphasen:

bull (starker Aufwärtstrend, wenn die Kursveränderung über einen Schwellwert von +2% liegt)

bear (starker Abwärtstrend, bei negativer Kursveränderung unter -2%)

sideways (Seitwärtsbewegung, Veränderungen innerhalb +-2%)

Nicht vollständige Zeilen werden entfernt.

2. Train-Test-Split und Feature-Definition

Die Features werden ausgewählt und die Daten werden in Trainings- und Testdaten (80:20) aufgeteilt.

3. Modellierung: Naiver Bayes

Algorithmus: Gaussian Naive Bayes

Training: Anpassung an die Trainingsdaten

Vorhersage: Prognose der Marktphasen auf den Testdaten

Evaluation: Ausgabe des Classification Report mit Genauigkeit (Accuracy), Precision, Recall und F1-Score für jede Klasse

4. Modellierung: Lineare Diskriminanzanalyse (LDA)

Algorithmus: Linear Discriminant Analysis (LDA)

Training: Anpassung an die Trainingsdaten

Vorhersage: Prognose der Marktphasen auf den Testdaten

Evaluation: Ausgabe des Classification Report mit denselben Metriken wie beim Naiven Bayes

4. Ergebnisse:



Naiver Bayes Klassifikation:

	precision	recall	f1-score	support
bear	0.55	0.66	0.60	152
bull	0.75	0.76	0.76	229
sideways	0.39	0.29	0.33	140
accuracy			0.61	521
macro avg	0.56	0.57	0.56	521
weighted avg	0.60	0.61	0.60	521



LDA Klassifikation:

	precision	recall	f1-score	support
bear	0.57	0.75	0.65	152
bull	0.77	0.79	0.78	229
sideways	0.47	0.29	0.36	140
accuracy			0.64	521
macro avg	0.60	0.61	0.60	521
weighted avg	0.63	0.64	0.63	521

Abbildung 18: Ergebnisse der Klassifikation (Classification Report) für Naive Bayes und LDA

○ Prophet-Modell

Im Jupyter Notebook werden zunächst die Preis- und Zeitreihendaten für Bitcoin (BTC) sowie Gold (XAU) aus CSV-Dateien eingelesen. Diese Daten werden mithilfe der Funktion `clean_price_column` aufbereitet: Nicht-numerische Zeichen werden entfernt, Kommas durch Punkte ersetzt und die Preisspalte in einen numerischen Datentyp umgewandelt. Ausreißer werden gefiltert, indem nur Werte zwischen 500 und 150.000 Einheiten berücksichtigt werden. Abschließend werden die Spalten passend für Prophet in „ds“ (Zeitpunkt) und „y“ (Wert) umbenannt. Mit den bereinigten Daten werden je ein Prophet-Modell für BTC und Gold erstellt und trainiert. Beide Modelle nutzen das tägliche Saisonalitätsmerkmal, um mögliche periodische Effekte zu berücksichtigen. Für die Prognose wird jeweils ein Zeitrahmen von 90 Tagen in die Zukunft generiert, und darauf basierend werden die erwarteten Werte berechnet.

Die Ergebnisse werden anschließend in einem Diagramm mit zwei Y-Achsen visualisiert: Auf der linken Achse werden die historischen und prognostizierten BTC-Preise dargestellt, auf der rechten Achse die entsprechenden Werte für Gold. Dies ermöglicht einen direkten Vergleich der zeitlichen Entwicklungen und Vorhersagen beider Anlageklassen innerhalb eines gemeinsamen Zeitraums ab 2018. Die Achsen sind eindeutig beschriftet, die Prognosen sind klar von historischen Daten getrennt und die Legende fasst alle Komponenten übersichtlich zusammen. So wird die Analyse übersichtlich und nachvollziehbar präsentiert.



Abbildung 19: BTC- und Goldpreis – Vergleich der Prophet-Vorhersagen

2.5 Evaluation

2.5.1 Detaillierte Analyse und Ergebnisse der Modelle wurden direkt unter der Data Preparation und Medelling evaualiert.

2.5.2 Bewertung in Bezug auf Ziele und Erfolgskriterien:

2.6 Deployment

Finaler Report:

Review und Lessons Learned:

3. Literaturverzeichnis

ABBILDUNG 1: TÄGLICHER VERLAUF DER SCHLUSSKURSE - BTC UND XAU (LOGARITHMISCH).....	4
ABBILDUNG 2: HISTOGRAMME FÜR VERGLEICH ZWISCHEN PREISE UND TECHNISCHEN INDIKATOREN FÜR BTC UND XAU NEBENEINANDER	5
ABBILDUNG 3: STREUDIAGRAMM – BTC-SCHLUSSKURS VS. XAU-SCHLUSSKURS	10
ABBILDUNG 4: STREUDIAGRAMME – RSI, MACD UND MA20 VS. PREIS (BTC UND XAU) UNTER EINBEZUG DES HANDELSVOLUMENS	11
ABBILDUNG 5: BOXPLOT DER TÄGLICHEN RENDITEN VON BTC UND XAU	12
ABBILDUNG 6: HEXAGONALES BINNING DER TÄGLICHEN RENDITEN VON BTC UND XAU	13
ABBILDUNG 7: HEXAGONALES BINNING – KORRELATION ZWISCHEN BTC- UND XAU-SCHLUSSKURSEN	14
ABBILDUNG 8: KORRELATIONSMATRIXEN - INTERNE ZUSAMMENHÄNGE BEI BTC UND GOLD SOWIE CROSS-KORRELATIONEN	15
ABBILDUNG 9: KONTINGENZTABELLE ALS HEATMAP – GEMEINSAME KURSBEWEGUNGEN BTC UND GOLD (UP/DOWN-VERHALTEN)	16
ABBILDUNG 10: HEATMAP - BTC VS. XAU PREISBEREICHE	16
ABBILDUNG 11: DICHTEVERTEILUNG DER ABSOLUTEN TÄGLICHEN RENDITEN (VOLATILITÄT) VON BTC UND XAU	18
ABBILDUNG 12: ERGEBNIS FÜR ERSTE ANAOVA-ANALYSE	19
ABBILDUNG 13: ERGEBNIS FÜR ZWEITE ANAOVA-ANALYSE (VERTEILUNG DER BOOTSTRAP-F-WERTE)	20
ABBILDUNG 14: ERGEBNIS FÜR DRITTE ANAOVA-ANALYSE (BTC-PREIS IN ABHÄNGIGKEIT VOM GOLD-HANDELSVOLUMEN (NIEDRIG, MITTEL, HOCH))	21
ABBILDUNG 15: ERGEBNIS FÜR CHI-QUADRAT-TEST (VERTEILUNG DER BOOTSTRAP-CHI ² -STATISTIK IM VERGLEICH ZUR BEOBACHTETEN STATISTIK).....	22
ABBILDUNG 16: MODELLERGEBNISSE DER MLR	23
ABBILDUNG 17: VERGLEICH DER TATSÄCHLICHEN UND VORHERGESAGTEN BTC-PREISE SOWIE DEREN ZEITLICHER VERLAUF	24
ABBILDUNG 18: ERGEBNISSE DER KLASSIFIKATION (CLASSIFICATION REPORT) FÜR NAIVE BAYES UND LDA.....	25
ABBILDUNG 19: BTC- UND GOLDPREIS – VERGLEICH DER PROPHET-VORHERSAGEN	26